

Beadandó feladat 2.

Vízminőség és szennyvízrendszerek elemzése az USA-ban

A beadandót .ipynb formátumú fájlban kell beadni.

A Jupyter Notebook formátumú fájlban minden feladat legyen külön kódcellára szétválasztva.

Az adatkészletről

Ez a felmérés az Egyesült Államok vízminőségével és szennyvízrendszereivel foglalkozik. Különböző helyekről gyűjtött adatokat elemzünk, hogy megtaláljuk a víz- és szennyvízgazdálkodás trendjeit és kihívásait. Ez az adatkészlet lehetőséget kínál a földrajzi elhelyezkedés, a nitrogén és foszfor szintek és a szennyvízrendszerek állapota közötti kapcsolat feltárására.

Oszlopleírások

Földrajzi hely szélesség (Latitude): Ez az oszlop a vízmintavételi helyek szélességi koordinátáit mutatja, jelezve azok észak-déli helyzetét a Földön.

Földrajzi hely hosszúság (Longitude): Ez az oszlop a hosszúsági koordinátákat tartalmazza, amelyek a mintavételi helyek kelet-nyugati helyzetét jelzik.

Mintavétel dátuma: Ez az oszlop azokat a dátumokat sorolja fel, amikor a vízmintákat vették, segítve az időbeli változások nyomon követését.

Nitrogén (mg/L): Ez az oszlop a vízminták nitrogénkoncentrációját adja meg, milligramm/literben (mg/l) mérve. A magas nitrogénszint szennyezésre utalhat.

Foszfor (mg/L): Ez az oszlop a vízminták foszforkoncentrációját mutatja, mg/l-ben is mérve. A nitrogénhez hasonlóan a magas foszforszint is hozzájárulhat a vízminőségi problémákhoz.

A szennyvízrendszer állapota: Ez az oszlop a mintavétel helyén a szennyvízrendszer állapotát írja le. Kategóriák: "Good" (jó), "Moderate" (mérsékelt) és "Poor" (gyenge), ami a szennyvízkezelés hatékonyságát jelzi.

Feladatok:

1. feladat: Importáljuk a megfelelő modulokat az adatelemzéshez és vizualizációhoz. Az adatokat töltsük be a data.csv fájlból egy dataframe-be és ellenőrizzük a művelet eredményét. 2 pont

2. feladat: **Adatok áttekintése:** Vizsgáljuk meg az adatkészletet, hogy megértsük annak szerkezetét és az adattípusokat. Jelenítsük meg ezt az információt a dataframe-ről. 0,5 pont

3. feladat: **Adatok előfeldolgozása:** Végezzünk adatelőkészítést az elemzés előtt. Alakítsuk át a mintavételi dátumot ("Sampling Date") dátum-idő formátumra, és ellenőrizzük, hogy vannak-e hiányzó értékek a dataframe-ben. 1,5 pont

4. feladat: **Feltáró adatelemzés:** Nézzük meg az adatokat néhány vizualizációval, hogy megértsük a szennyezőanyagok szintjeinek eloszlását és a szennyvízrendszerek állapotát a különböző földrajzi helyeken.

a) Ábrázoljuk a nitrogén és foszfor szintek eloszlását Matplotlib histogram-mal két subplot elhelyezésével egy közös ábrán. Az ábra méretét célszerű 12x6-ra beállítani.

A diagramokat lássuk el jelmagyarázattal, diagramcímmel és tengelyfeliratokkal. A diagramokban a KDE is kerüljön ábrázolásra. 2,5 pont

b) Ábrázoljuk a nitrogén szintek geográfiai eloszlását scatter-en, ahol a vízszintes tengelyen a Longitude és a függőleges tengelyen a Latitude értékek szerepeljenek. A hue paramétert a 'Nitrogen (mg/L)' értékekre állítsuk be, és használjunk 'coolwarm' színpalettát. 2 pont

5. feladat: **Ábrázoljuk a foszfor szinteket valós térképen:** Hozzuk létre a map objektumot és jelenítsük meg az interaktív térképet az adott GPS koordináták alapján. 3 pont

A színeket a következő kóddal adjuk meg:

```
from matplotlib import colors
max_P = round(df['Phosphorus (mg/L)'].max())
print(max_P)
levels = range(max_P+1)
color_dict = dict(zip(levels, list(colors.cnames.values())[0:-1:10]))
color_dict
```

6. feladat: **A szennyvízrendszer állapota:** Készítsünk gyakoriság diagramot a State of Sewage System lehetséges állapotairól. Használjuk a Seaborn histplot metódusát és a kép méretét 6x6-osra állítsuk be. A diagramot lássuk el jelmagyarázattal, diagramcímmel és tengelyfeliratokkal. 2,5 pont

7. feladat: **Korrelációs elemzés:**

a) Vizsgáljuk meg az adatkészlet numerikus változói közötti korrelációt, hogy azonosítani tudjuk az esetleges kapcsolatokat. Először hozzuk létre az N+P oszlopot, ahol a teljes mért szennyezés értékét (a nitrogén és foszfor mennyiségek összegét) jelenítjük meg a mérési helyeken, a mért időpontokban. 1 pont

b) A szennyvízrendszer állapotát megadó State of Sewage System oszlop adatait konvertáljuk számértékké a LabelEncoder alkalmazásával. Ellenőrizzük az eredményt. 2 pont

c) Válogassuk ki a csak numerikus adatokat tartalmazó oszlopokat egy új dataframe-be, végezzük el a korreláció vizsgálatát a pearson módszer alkalmazásával. A korreláció vizualizációhoz használjunk heatmap diagramot, a korrelációs együtthatók megjelenítésével (3 tizedesjegyre kerekítve), **coolwarm** színtérképpel, 8x6-os képmérettel és diagramcímmel. 4,5 pont

8. feladat: **Rövidítsük a mezőneveket a következőképpen:**

```
Lati = Geographical Location (Latitude)
Long = Geographical Location (Longitude)
SDate = Sampling Date
N = Nitrogen (mg/L)
P = Phosphorus (mg/L)
SWS = State of Sewage System
```

Ellenőrizzük az info() metódussal, hogy sikeres volt-e az átnevezés. 1,5 pont

9. feladat: **Készítsük el az adatok statisztikai jellemzését:** Használjuk a describe() utasítást. 1 pont

10. feladat: Vizsgáljuk meg azokat a helyeket, ahol a N+P koncentráció magas. Ehhez készítsünk egy Q (quality) oszlopot az apply függvény alkalmazásával, a következő értékekkel:

1, ha N+P 4-nél kisebb; 3, ha 10-nél nagyobb; a közbeeső tartományra az érték legyen 2. Ellenőrizzük az eredményt. 2,5 pont

11. feladat: Csoportosítsuk a Q oszlop értékeit és írassuk ki a csoportok méretét. 1,5 pont

12. feladat: Jelenítsük meg a Q értékek geográfiai eloszlását Seaborn scatterplot-tal, **coolwarm** színpalettával. A kép méretét 10x6-osra és a hue paramétert a Q értékekre állítsuk be. A diagramot lássuk el jelmagyarázattal, diagramcímmel és tengelyfeliratokkal. 1 pont

Az adatok elemzése Machine Learning modellek alkalmazásával

13. feladat: A következő részben készítsünk egy elemzést a **DecisionTree** modellel, a kapott modell értékelésével, és a döntési fa megjelenítésével. Importáljuk a szükséges modulokat és osztályokat a Scikit-learn könyvtárból.

Ebben az elemzésben nem használjuk a dátum adatokat, ezért a vizsgálathoz hozzunk létre egy új dataframe-et az SDate oszlop nélkül. Ellenőrizzük az új dataframe-et.

A modell alkalmazásához erre az új dataframe-re válasszuk szét az adathalmazt független (`x`) és függő (`y`) változókra, az y értékeknek az SWS oszlopot választva. 4,5 pont

14. feladat: **Adatok felosztása, modellépítés és betanítás. Vizualizáció**

Osszuk fel az adatokat 4:1 arányban véletlenszerűen train és test adatokra, és tanítsuk be a modellünket. Vizualizáljuk a döntési fát a Matplotlib segítségével, az ábra méretét célszerű 12x8-ra beállítani. 4 pont

15. feladat: **A modell értékelése**

Készítsünk predikciót a teszt halmazon. Számítsuk ki a pontosságot. Generáljunk osztályozási riportot és konfúziós mátrixot és ezeket jelenítsük meg. 4 pont

16. feladat: **A népesség és a szennyezettség mértékének kapcsolatának vizsgálata Lineáris Regresszióval**







A következő részben készítsünk egy elemzést a LinearRegression modellel, a kapott modell értékelésével, és a scatter diagram megjelenítésével. Először importáljuk a szükséges modulokat és osztályokat a Scikit-learn könyvtárból. Független változónak a Population oszlopot, és függő változónak az N+P oszlopot válasszuk.

Osszuk fel az adatokat 4:1 arányban véletlenszerűen train és test adatokra, és tanítsuk be a modellünket. Vizualizáljuk a teszt adatokat és a lineáris regressziót is jelenítsük meg a Matplotlib scatter alkalmazásával. 8,5 pont

17. feladat: **A modell értékelése**

Készítsünk predikciót a teszt halmazon, és jelenítsük meg az első öt predikció, és az első öt valós y teszt értékeket. Írassuk ki a betanított modellünk pontosságát is. 4 pont

A következő oldalon található a feladatban megjelenített néhány diagram képe mintaként (ahol a feladatban nincs pontos színmeghatározás, ott a mintaként megadott színeket alkalmazzd):



Kérdés esetén a gyakorlatvezetőhöz lehet fordulni.

Az elérhető maximális pontszám: 54 pont

Jó munkát!